

학 사 학 위 논 문

무작위 유저 혼합 환경의 목표 난이도 추종을 위한 보상 모델 설계 및 한계 분석

(Design and Limitation Analysis of Reward Model for
Tracking Target Difficulty in Randomized User Mixed
Environments)



경희대학교 소프트웨어융합학과

최성우

2026년 6월

<목 차>

I. 서론

- 1.1. 연구의 배경 및 필요성
- 1.2. 기존 보상 모델의 한계 및 문제 제기
- 1.3. 제안 모델 및 연구의 핵심 기여도

II. 관련 연구

- 2.1. 경험 기반 절차적 콘텐츠 생성 및 게임 밸런싱
- 2.2. Unity ML-Agents 와 다중 목표 조건부 학습의 한계
- 2.3. 강화학습에서 보상 함수 설계

III. 제안 방법

- 3.1. 다중 실력 기반 플레이어 페르소나 모델링
- 3.2. 무작위 유저 혼합 환경 및 보스 에이전트 정의
- 3.3. 가우시안 보상 함수 설계

IV. 실험 및 결과 분석

- 4.1. 학습 성능 비교 및 절제 연구
- 4.2. 목표 난이도별 추론 성능 및 분포 외 한계 분석

V. 결론

<요 약>

본 연구는 액션 게임의 PVE 콘텐츠 밸런싱 과정에서 발생하는 기획자의 수동 테스트 비용을 절감하고, 목표 난이도를 정밀하게 추종하는 자동화된 밸런싱 파이프라인을 제안한다. 이를 위해 실력별 플레이어 페르소나(초보자, 중급자, 숙련자)가 무작위로 혼합된 환경에서 보스 에이전트가 목표 클리어율을 학습하는 다중 목표 조건부 강화학습 모델을 구축하였다.

기존의 선형 보상 함수가 갖는 '보상 착시'와 '학습 정체' 문제를 해결하기 위해, 오차율에 따라 지수적으로 패널티가 증가하는 가우시안 보상 함수를 설계하여 정책 최적화 성능을 향상시켰다. 실험 결과, 제안하는 가우시안 보상 모델은 선형 모델 대비 안정적인 학습 수렴 곡선을 보였으며, 50% 목표 난이도 환경에서 평균 27.3%의 실제 클리어율을 기록하며 환경적 하한선 내 최적 정책을 확립하였다. 또한, 20% 및 80%의 극단적 타겟 테스트를 통해 시뮬레이션 환경에 내재된 물리적 상한선과 에이전트의 정책 붕괴 현상을 규명하였다. 특히, 최적 밸런스 산출 과정에서 보스 에이전트가 구조적으로 비효율적인 특정 패턴을 스스로 배제하는 현상을 입증함으로써, 본 파이프라인이 단순 밸런싱을 넘어 전투 디자인의 결함을 데이터 기반으로 검증하는 자동화된 QA(Quality Assurance) 도구로서의 실무적 가치를 가짐을 증명하였다.

I. 서 론

1.1. 연구의 배경 및 필요성

게임 밸런싱은 플레이어의 몰입도와 게임의 수명을 결정짓는 핵심 요소이다. 최근 인공지능 기술의 발달과 함께, 기획자의 수동 테스트에 의존하던 전통적 방식에서 벗어나, 강화학습(RL) 에이전트를 활용한 난이도 자동화 연구가 활발히 진행되고 있다. 대표적으로 동적 난이도 조절 기법(dynamic difficulty adjustment, DDA)은 플레이어의 실시간 데이터를 바탕으로 1:1 맞춤형 난이도를 제공해 왔다.

그러나 기존 DDA 방식은 개별 플레이어의 수준에 따라 적의 체력이나 패턴이 임의로 변동되므로, 게임 시스템의 일관성을 훼손하고 플레이어의 성취감을 저하시키는 한계가 존재한다. 이에 대한 대안으로 무작위 유저 혼합 환경에서 경험 기반 절차적 콘텐츠 생성(Experience-driven Procedural Content Generation, EDPCG) 방법론이 대두되고 있다. 본 연구에서 제안하는 EDPCG 밸런싱은 개별 유저에게 난이도를 맞추는 것이 아니라, 초보자부터 고수까지 무작위로 혼합된 거시적인 유저 풀 환경에서 기획자가 설정한 목표 난이도를 달성할 수 있는 통일된 레벨 디자인을 알고리즘이 자동 산출하는 것을 목적으로 한다.

1.2. 기존 보상 모델의 한계 및 문제 제기

강화학습을 활용하여 EDPCG 환경의 난이도 추종 에이전트를 학습시킬 때, 가장 중요한 과제는 목적 함수인 보상 모델의 설계이다. 기존 강화학습 연구에서는 구현의 용이성으로 인해 주로 오

차에 비례하여 보상이 감소하는 선형 보상 함수를 채택해 왔다.

하지만 플레이어의 체력, 무적 시간, 무작위 스킬 등 비선형적 물리 요소가 결합된 액션 게임 환경에서 선형 보상 모델은 치명적인 수학적 결함을 지닌다. 선형 함수의 완만한 기울기는 에이전트가 목표 오차율을 크게 벗어난 상태(예: 30% 이상의 오차)에서도 여전히 양수(+)의 보상을 획득하게 만드는 보상 착시를 유발한다. 이는 에이전트가 오차를 줄이기 위한 정밀한 미세 조정(Fine-tuning)을 포기하고 국소 최적해(Local Minima)에 조기 수렴하게 만드는 주요 원인으로 작용한다.

또한, 다중 목표를 추종하도록 설계된 조건부 에이전트라 할지라도, 기획자가 시뮬레이션 생태계의 구조적 한계치를 벗어난 극단적인 난이도를 요구할 경우 보상 그래디언트(Gradient)를 상실하여 파라미터가 발산하는 정책 붕괴(Policy Collapse) 현상을 겪게 된다. 이는 자동 밸런싱 시스템의 가동 범위가 환경 내재적 제원에 의해 구속됨을 뜻하며, 시스템 신뢰성 확보를 위해 난이도별 행동 변화와 환경의 물리적 한계에 대한 명확한 분석이 선행되어야 함을 시사한다.

1.3. 제안 모델 및 연구의 핵심 기여도

이에 본 연구는 무작위 유저 혼합 환경에서 EDPCG 방법론을 기반으로 기획자의 목표 난이도를 안정적으로 추종하기 위해, 기존 선형 모델의 한계를 극복하는 가우시안 보상 모델(Gaussian Reward Model) 기반의 밸런싱 파이프라인을 제안하고 그 한계점을 분석한다. 본 연구의 핵심 기여도는 다음과 같다.

- **목표 난이도 추종을 위한 가우시안 보상 모델 제안:** 오차율에 따라 비선형적으로 변하는 가우시안 목적 함수를 도입하여, 에이전트가 조기 정체 없이 안정적인 미세 조정(Fine-tuning)을 수행하도록 유도한다.
- **절제 연구(Ablation Study)를 통한 수렴성 증명:** 선형 보상 함수와의 비교 실험을 통해 기존 모델의 수렴 실패 원인을 규명하고, 제안하는 가우시안 보상 모델이 누적 보상의 안정적인 우상향과 유의미한 정책 최적화를 효과적으로 유도함을 증명한다.
- **시뮬레이션 환경의 구조적 제약 및 자동 QA 가치 분석:** 양극단의 타겟(20%, 80%) 추론 테스트를 통해 시뮬레이션 환경이 허용하는 클리어율의 구조적 상한선을 규명하고, 에이전트의 가중치 분포 변화를 통해 기획 초기 단계에서 전투 패턴의 결함을 판별하는 자동화된 QA 도구로서의 확장 가능성을 실증한다.

II . 관련 연구

2.1. 경험 기반 절차적 콘텐츠 생성 (EDPCG) 및 게임 밸런싱

전통적인 게임 밸런싱은 기획자의 수동 테스트나 휴리스틱에 크게 의존해 왔다. 이를 자동화하기 위해 Yannakakis & Togelius (2011)는 플레이어의 상호작용 데이터를 기반으로 콘텐츠를 절차적으

로 생성하는 EDPCG 개념을 제안하였다. 이 연구는 플레이어의 경험을 정량화하여 맞춤형 난이도를 제공하는 데 기여했으나, 다양한 실력의 플레이어가 무작위로 혼합된 환경에서 거시적 통계를 기반으로 전체 시스템의 목표 승률을 조정하는 밸런싱 모델로의 확장은 부족했다. 본 연구는 EDPCG 개념을 발전시켜, 개별 유저가 아닌 N=100 유저풀의 통계적 결과를 관측값으로 삼는 통합 밸런싱 자동화 시스템을 구축한다.

2.2. Unity ML-Agents 환경과 다중 목표 조건부 학습의 한계


게임 환경 내 지능형 에이전트 학습을 위해 Juliani 외 (2018)는 Unity ML-Agents 환경과 PPO(Proximal Policy Optimization) 알고리즘의 결합을 표준 방법론으로 제시하였다. PPO는 정책 업데이트의 폭을 제한하여 안정적인 수렴을 보장하는 장점이 있어 게임 AI에 널리 채택되고 있다. 그러나 다양한 타겟 수치를 동적으로 추종해야 하는 다중 목표 조건부(Goal-Conditioned) 강화학습 환경에서는, 에이전트의 알고리즘적 학습 능력과 별개로 시뮬레이션 생태계 자체가 지닌 물리적 한계 시스템의 성능을 구속할 수 있다. 본 연구는 PPO 알고리즘을 기반으로 다중 목표를 관측하는 보스 에이전트를 학습시키되, 극단적인 목표 난이도(예: 20%, 80%)가 주어졌을 때 환경적 상한선에 부딪힌 에이전트의 정책 붕괴 현상을 실증적으로 규명한다.

2.3. 강화학습에서 보상 함수 설계

강화학습 에이전트의 목표 달성 효율은 목적 함수인 보상 구조에 의해 결정된다. Devlin & Kudenko (2012)는 동적 환경에서 에이전트의 조기 수렴 정체를 방지하기 위해 비선형적 보상 형태의 수학적 타당성을 증명하였다. 다수의 게임 AI 연구가 오차에 비례해 일정하게 감소하는 선형 보상 함수를 사용해 왔으나, 이는 오차가 큰 상황에서도 양수 보상을 제공하는 착시 현상을 유발하여 에이전트의 미세 조정을 방해한다. 본 연구는 이러한 선형 보상의 수학적 결함을 대조 실험으로 규명하고, 오차 구간에 따라 페널티와 보상 기울기가 가파르게 변하는 가우시안 보상 모델을 대안으로 설계하여 수렴성을 입증한다.

III . 제안 방법

본 연구는 설정된 타겟 클리어율(예: 50%)에 수렴하는 PVE 보스 전투 콘텐츠를 생성하기 위해, 플레이어 페르소나 에이전트와 보스 에이전트 간의 비대칭적 상호작용 환경을 구축한다. 제안하는 파이프라인은 크게 플레이어 페르소나 모델링, 무작위 유저 혼합 환경 및 보스 에이전트 정의, 그리고 가우시안 보상 함수 설계의 세 단계로 구성된다. 에이전트의 학습 및 시뮬레이션은 Unity 3D 엔진 기반에서 진행되었으며, 연속적이고 복잡한 환경에서 안정적인 정책 수렴 성능을 보이는 PPO 알고리즘을 채택하였다.



[그림 1] EDPCG 기반 목표 난이도 추종 밸런싱 시스템 파이프라인 및 피드백 루프

[그림 1]은 본 연구에서 제안하는 통합 밸런싱 시스템의 전체 아키텍처와 강화학습 피드백 루프를 나타낸다. 기획자가 목표 난이도를 입력하면, 보스 에이전트는 현재 환경의 상태(목표치, 무기 스펙, 페르소나 타입)를 관측하여 최적의 쿨타임과 패턴 가중치를 행동으로 출력한다. 산출된 파라미터를 바탕으로 N=100의 무작위 유저풀이 배치 시뮬레이션을 수행하며, 완료 후 통계적으로 도출된 실제 클리어율과 목표치 간의 오차를 가우시안 보상 함수를 통해 페널티와 보상으로 환산하여 에이전트의 정책을 최적화한다.

3.1. 다중 실력 기반 플레이어 페르소나 모델링

실제 플레이어의 다양한 실력을 시뮬레이션 환경에 반영하기 위해, 본 연구는 플레이어 에이전트를 기반으로 인간의 인지적 한계와 조작 오류를 모사한 '다중 페르소나'를 구축하였다.

1) 행동 공간 및 공격 메커니즘 최적화

플레이어 에이전트의 이동 제어는 신속한 반응과 세밀한 조작이 가능하도록 수평 이동(좌우 이동 및 대쉬)과 수직 이동(최대 2단 점프 및 숙이기)의 이산적 행동 공간으로 구성하였다. 일반적인 액션 게임의 복잡한 공격 입력 로직은 상태 공간을 불필요하게 확장시켜 학습 효율을 저하할 우려가 있으므로, 본 연구에서는 명시적인 공격 입력 대신 '근접 체류 기반 지속 피해' 방식을 채택하였다. 에이전트가 보스 주변의 특정 공격 가능 범위 내에 체류할 경우 공격 판정이 발생한 것으로 간주하며, 체류 시간에 비례하는 보상을 부여함으로써 적극적인 접근을 유도하였다.

2) 관측 공간(Observation Space) 설계

에이전트가 보스의 다중 패턴을 인지하고 최적의 동선을 결정할 수 있도록 총 20차원의 상태 관측 벡터를 설계하였다. 시간적 흐름에 대한 인지 능력을 향상시키기 위해, 공격 예고 판정 발동 여부를 단순한 불리언(Boolean)이 아닌 예고 후 흐른 시간에 대한 정규화된 연속형 변수로 전달하여 관측 공간을 고도화하였다.

3) 단일 마스터 모델 도입 및 휴리스틱 제약을 통한 페르소나 분화

초기 연구에서는 실력별 페르소나를 구현하기 위해 판단 주기(Decision Period, DP)를 차등 적용하여 개별 학습을 시도하였으나, 최고 숙달자 모사 시(DP=2) 에이전트가 파국적 망각(Catastrophic Forgetting)에 빠지는 불안정성이 발생하였다. 이를 해결하기 위해, 인간의 유의미한 최소 반응 속도에 가장 근접한 DP=5(약 0.1초) 환경에서 회피 성능이 극대화된 단일 마스터 모델을 우선 학습

시켰다.

이후 추론(Inference) 단계에서 인간의 인지적, 신체적 한계를 모사한 통제 변인을 차등 적용하는 방식으로 3단계의 실력별 페르소나를 확립하였다. 각 페르소나의 예상 회피율은 보스가 4가지 핵심 패턴을 무작위로 약 1,000회 시전하는 통제된 테스트 환경에서 도출된 경험적 통계치이며, 세부 설정은 다음과 같다.

- **Expert (숙련자 - 예상 회피율 91%):** 높은 수준의 반사 신경과 숙련도를 모사하여, 인지적 지연(Delay)이나 조작 실수를 배제하고 마스터 모델의 최적 회피 기동을 온전히 수행한다.
- **Intermediate (중급자 - 예상 회피율 74%):** 일반적인 게이머의 반응 지연을 반영하기 위해, 위험 인지 시 0.1초의 인지적 마스킹(Cognitive Masking)을 적용하였으며, 독립 시행마다 5% 확률의 조작 실수(RNG Error)가 발생하도록 설정하였다.
- **Beginner (초보자 - 예상 회피율 69%):** 패턴 파악이 미숙한 초보 플레이어의 한계를 모사하여, 인간 평균 반응 속도인 0.25초의 인지적 마스킹을 적용하였고, 15%의 높은 확률로 입력 누락 및 회피 방향 오류 등의 심각한 조작 실수를 유발하도록 구현하였다.


3.2. 무작위 유저 혼합 환경(EDPCG) 및 보스 에이전트 정의

전통적인 DDA(동적 난이도 조절)는 단일 유저의 실력에 맞춰 실시간으로 난이도를 변동시키므로, 출시 전 고정된 환경 밸런스를 검증하는 데 한계가 있다. 따라서 본 연구는 EDPCG 방법론의 핵심 목적(전체 유저 생태계에 적합한 단일 난이도 파라미터 산출)에 부합하도록, 앞서 구축한 3가지 페르소나(Beginner, Intermediate, Expert)가 무작위 확률로 혼합되어 등장하는 통합 유저풀을 본 학습 환경으로 전환하였다. 보스 에이전트는 이 환경에서 기획자의 의도에 맞춰 전투 난이도 파라미터를 실시간으로 산출하는 통합 밸런싱 시스템의 중추 역할을 수행한다.

1) 보스 패턴 및 상호작용 로직

보스 에이전트는 타겟 클리어율을 달성하기 위해 4가지의 핵심 패턴을 조합하여 사용한다. 각 패턴은 플레이어 페르소나의 반응 속도와 특정 조작 능력을 검증하도록 설계되었다.

- **상단 공격 패턴:** 플레이어의 수직 회피(숙이기) 능력 및 하단 판정 반응 속도 측정.
- **하단 공격 패턴:** 플레이어의 체공 기반 회피(점프) 능력 및 반응 속도 측정.
- **대쉬 요구 패턴:** 플레이어의 순간적인 수평 이탈(대쉬) 능력 및 반응 속도 측정.
- **체류 억제 패턴:** 공격 범위 이탈을 강제하여 무분별한 접근 방지 및 회피 로직 유도.



[그림 2] 보스 공격 패턴

이 과정에서 단일 에피소드가 단 1회의 죽음으로 종료될 경우, 실력적 요인이 아닌 우연한 조작 실수로 인해 클리어율 통계에 극단값이 발생할 위험이 있다. 이를 완화하고 통계적 왜곡을 방지하기 위해, 본 연구는 플레이어 에이전트에게 에피소드당 총 3개의 라이프(Life)를 부여하였다. 피격 시 에이전트의 위치 초기화 없이 잔여 라이프만 차감되는 연속적인 방식을 채택함으로써, 시공간적 단절 없이 무작위성에 의한 분산을 최소화하고 목표 난이도 추종의 정밀도를 대폭 향상시켰다.

2) 상태 및 행동 공간 설계

이 환경에서 보스 에이전트는 개별 유저의 정보를 직접 관측할 수 없는 블라인드 상태에 놓이며, 거시적 통계에 기반한 3차원의 연속형 상태를 관측한다.

- 기획자가 설정한 목표 클리어율 (0.2 ~ 0.8)
- 현재 조우한 플레이어 페르소나의 확률적 통계 분포 (N=100 유저풀의 페르소나 비율)
- 현재 플레이어의 스펙 (최소~최대 체력 대비 정규화 된 DPS 값)

관측된 상태를 바탕으로 보스는 5차원의 연속형 행동을 출력한다.

- **패턴 주기 (1차원):** 0.1 ~ 3.0초 사이의 공격 주기를 연속적인 값으로 조절한다.
- **패턴 가중치 (4차원):** 4가지 핵심 패턴의 등장 확률 가중치를 연속적인 값으로 출력하여 최적의 템포와 조합을 결정한다.

3.3. 가우시안 보상 함수 설계

강화학습에서 에이전트의 행동을 최적화하는 핵심은 목적 함수인 보상 구조에 있다. 본 연구는 단일 에피소드 평가와 선형 보상 함수의 한계를 극복하기 위해 배치 평가 기반의 가우시안 보상 모델을 도입하였다.

1) 배치 평가(Batch Evaluation) 시스템 도입

초기 연구 단계에서는 플레이어의 단일 게임(1 에피소드) 승패 여부에 따라 보스에게 즉각적인 보상을 부여하였다. 그러나 1회성 게임의 결과는 항상 0%(패배) 또는 100%(승리)의 극단적인 이산값으로만 나타나, 보스 에이전트가 난이도 파라미터를 극단적으로 조절하는 오실레이션(Oscillation) 문제를 유발하였다. 이를 해결하기 위해 보스가 산출한 파라미터로 무작위 페르소나가 N회(N=100)의 에피소드를 연속 수행한 후, 도출된 실제 클리어율 평균과 목표 클리어율 간의 오차를 계산하여 보상을 부여하는 배치 평가 시스템을 구축하였다.

2) 가우시안 보상 함수 제안

오차율에 비례하여 일정한 비율로 보상이 감소하는 기존의 선형 보상 함수는 오차가 큰 상태(예: 30% 초과)에서도 에이전트에게 양수(+)의 보상을 지급하는 '보상 착시'를 유발한다. 이는 에이전트가 오차를 좁히려는 정밀한 미세 조정을 포기하고 국소 최적해에 정체하게 만드는 주된 원인이다.

이러한 한계를 극복하기 위해, 오차율에 따라 보상 기울기가 비선형적으로 변하는 가우시안 보상 모델을 다음과 같이 정의한다.

$$R(Error) = \begin{cases} 1.0 & \text{if } Error \leq Tolerance \\ 2 \cdot \exp\left(-\frac{(Error-Tolerance)^2}{2\sigma^2}\right) - 1 & \text{if } Error > Tolerance \end{cases}$$

위 수식에서 Error는 목표 클리어율과 실제 클리어율의 절대 오차(|Target Clear Rate - Actual Clear Rate|)를 의미하며, Tolerance는 기획자가 허용하는 오차 범위(본 연구에서는 0.05로 설정)이다.

δ (Sigma)는 페널티 민감도를 결정하는 가우시안 곡선의 폭을 나타낸다.

제안된 가우시안 수식은 오차가 허용 범위를 벗어나는 순간 지수적 감소를 발생시켜 급격하게 음수(-) 보상으로 전환된다. 이를 통해 보스 에이전트는 정답과 먼 오답 구간을 빠르게 이탈하며, 기획자가 설정한 타겟 클리어율을 향해 정밀하게 미세 조정을 수행하도록 강제된다.

IV . 실험


본 장에서는 제안한 가우시안 보상 모델의 학습 성능과 타겟 난이도 추종 능력을 검증하기 위한 실험 결과를 제시한다. 모든 실험은 Unity ML-Agents 환경에서 동일한 하이퍼파라미터를 적용하여 수행되었으며, 선형 보상 모델을 대조군으로 설정하여 제안 모델과의 수렴 성능을 정량적으로 비교한다.

4.1. 학습 성능 비교 및 절제 연구


1) 실험 환경 및 하이퍼파라미터 본 연구의 모든 에이전트는 근접 정책 최적화(PPO) 알고리즘을 기반으로 학습되었다. 모델의 일반화 성능과 안정적인 학습을 위해 설정한 주요 하이퍼파라미터는 [표 1]과 같다.

하이퍼파라미터	설정 값	하이퍼파라미터	설정 값
Batch_size	128	Buffer_size	1024
Learning_rate	3.0e-4	Num_epoch	3
Hidden_units	128	Num_layers	2
Time_horizon	128	Gamma	0.99
Max_steps	150,000	Learning_rate_schedule	linear

[표1 보스 에이전트 학습 하이퍼파라미터]



(a) 선형 보상 모델



(b) 가우시안 보상 모델

[그림 3] 보상 모델에 따른 강화학습 학습 곡선 비교

[그림 3]은 동일한 환경 및 하이퍼파라미터 조건에서 학습된 두 모델의 누적 보상(Cumulative Reward) 수렴 과정을 비교한다. 선형 보상 모델(a)은 학습 초기부터 목적 함수인 타겟 클리어율에 도달하지 못한 채 35,000 스텝 구간에서 의미 있는 우상향 없이 심각한 오실레이션과 학습 정체 현상을 보였으며, 유의미한 정책 개선이 불가능하다고 판단하여 학습을 조기 종료하였다. 반면,

제안하는 가우시안 보상 모델(b)은 학습 초기의 깊은 페널티 구간을 빠르게 이탈한 후, 최종 150,000 스텝까지 지수적 감소를 통해 학습 방향성을 명확히 유지하며 누적 보상이 뚜렷하게 우상향하는 성능을 입증하였다.

2) 보상 모델에 따른 학습 성능 및 환경적 분산 분석

실험 결과, 선형 보상 모델은 학습 초기 단계부터 목적 함수가 목표 값에 다가가지 못하고 광범위한 진동을 반복하는 현상을 보였다. 35,000 스텝 경과 시점까지 에이전트는 국소 최적해 내에서 의미 있는 정책 개선을 이루지 못하고 파라미터가 발산하는 불안정성을 노출하였다. 이는 선형 함수의 완만한 기울기가 오차가 큰 상황에서도 에이전트에게 양수(+)의 보상을 지급하는 '보상 착시' 현상을 일으켜, 잘못된 학습 방향을 지속적으로 제공했음을 시사한다.

반면, 동일한 하이퍼파라미터 환경에서 가우시안 보상 모델을 도입한 에이전트는 지수 함수 기반의 목적 함수를 통해 이러한 한계를 극복하였다. 학습 초기, 타겟을 크게 벗어난 에이전트는 수식에 따라 최하 -1.6328에 달하는 강력한 음수 페널티를 부여받았으며, 이는 에이전트가 탐색(Exploration) 구간을 빠르게 단축하고 오답 구간을 강제로 탈출하도록 만드는 강력한 동기로 작용하였다. 그 결과 35,000 스텝 전후로 누적 보상이 확연한 우상향 곡선을 그리기 시작하였다.

주목할 점은 100,000 스텝 이후의 학습 후반부 구간이다. 그래프(b)에서 관찰되듯, 가우시안 에이전트의 누적 보상은 일직선으로 완전히 평탄화(Flat)되지 않고 일정 구간 내에서 지속적인 진동 양상을 보인다. 이는 에이전트의 학습 불안정성이나 수렴 실패가 아니라, 본 연구가 채택한 무작위 유저 혼합 환경의 내재적 노이즈에 기인한 현상이다.

배치 평가 시스템 특성상, 매 에피소드마다 N=100명의 유저풀을 구성하는 초보자, 중급자, 숙련자의 비율이 무작위로 스폰되며, 개별 페르소나의 조작 실수(5~15%) 확률이 독립 시행으로 작용한다. 따라서 보스 에이전트가 타겟에 근접한 최적의 쿨타임을 출력하더라도 도출되는 실제 클리어율에는 필연적으로 통계적 오차가 동반된다. 가우시안 보상 모델은 이러한 동적이고 불규칙한 환경 노이즈 속에서도 학습의 방향성을 잃지 않았으며, 변화하는 유저풀의 무작위성에 맞춰 타겟 클리어율을 쫓아가기 위한 끊임없는 미세 조정을 수행하고 있음을 위 그래프의 진동 양상이 실증적으로 대변한다.

4.2. 목표 난이도별 추론 성능 및 분포 외 한계 분석

본 절에서는 0.2부터 0.8 사이의 무작위 목표 난이도를 지속적으로 관측하며 정책을 최적화한 다중 목표 조건부 에이전트의 추론 성능을 분석한다. 특히, 기획자가 설정한 타겟 클리어율(20%, 50%, 80%)에 따라 에이전트의 거동이 어떻게 변화하는지 비교하고, 시뮬레이션 환경에 내재된 물리적 제약이 시스템에 미치는 한계를 규명한다. 총 40회의 배치 시뮬레이션을 수행하여 도출한 타겟별 주요 지표는 [표 2]과 같다.

기획 목표치	실제 클리어율 (최소~최대)	평균 오차율	평균 쿨타임	패턴 엔트로피
0.2 (20%)	8.3% (0%~62%)	15.5%	0.685s	1.490

0.5 (50%)	27.3% (1%~79%)	32.8%	1.007s	1.719
0.8 (80%)	3.4% (0%~27%)	76.5%	0.428s	1.523

[표 2] 목표 난이도(Target) 설정에 따른 보스 에이전트의 추론 결과 비교 (각 N=40 평균치)¹

1) 학습 분포 내 단일 타겟 추론 및 환경적 제약 분석

먼저 50% 타겟 환경에서의 실험 결과, 보스 에이전트는 기획자가 설정한 타겟(0.5)에 완벽히 도달하지 못하고 평균 27.3%의 실제 클리어율을 기록하며 구조적 오차를 나타냈다.

그러나 주목할 점은 이때의 패턴 정보 엔트로피(Entropy)가 평균 **1.719**로 3개의 테스트 케이스 중 가장 높게 유지되었다는 것이다. 이는 에이전트가 학습에 실패하여 국소 최적해에 빠진 것이 아니라, 기획자의 의도대로 4가지 패턴을 고르게 활용하는 유의미한 행동 정책을 확립했음을 시사한다. 즉, 본 시뮬레이션 환경에 구성된 N=100 무작위 유저 풀의 물리적 회피 능력 한계와 보스 캐릭터의 기본 제원(데미지 및 피격 판정) 격차로 인해, 에이전트가 통제할 수 있는 행동 공간(Action Space) 내에서는 50% 달성이 구조적으로 불가능한 하한선에 직면한 것으로 분석된다.

가우시안 보상 함수는 이러한 환경적 제약 속에서도 도달할 수 있는 최선의 균형점(클리어율 27%)을 찾아 정책을 안정화시켰다. 특히 실제 클리어율의 극심한 편차(최솟값 1%, 최댓값 79%)는 무작위 유저풀이 만들어내는 내재적 노이즈를 의미하며, 에이전트가 이에 대응하여 평균 1.0초의 쿨타임을 동적으로 조절하며 치열하게 타겟을 추종하고 있음을 실증한다.

이러한 환경적 제약 속에서 다중 페르소나 생태계의 실제 작동성을 검증하기 위해, 오차율이 가장 낮았던 최적의 밸런스 파라미터(쿨타임 1.228초, 패턴 가중치 [0.49, 0.00, 0.34, 0.17])를 정적(Static)으로 고정하여 단일 배치(N=100) 추론 테스트를 수행한 결과는 [표 3]과 같다.

페르소나 그룹	배치 내 스폰 수	생존자 수	그룹 내 생존율
Beginner (초보자)	41	8	19.5%
Intermediate (중급자)	34	21	61.8%
Expert (숙련자)	25	19	76.0%
총합	100	48	48.0%

[표 3] 최적 파라미터 주입 시 목표 난이도 50% 환경의 페르소나별 생존율

분석 결과, 전체 클리어율은 48.0%를 기록하며 기획자의 타겟 난이도(50%)에 오차 범위 2% 내로 완벽히 수렴하였다. 세부 지표를 살펴보면, 인지적 마스킹(0.25초)과 높은 조작 실수(15%)가 부여

¹ 실제 클리어율 괄호 안의 수치는 40회 시뮬레이션 중 관찰된 최솟값과 최댓값을 의미함.

된 초보자 그룹은 19.5%의 낮은 생존율을 보인 반면, 통제 변인이 적은 중급자와 숙련자 그룹은 각각 61.8%와 76.0%의 높은 생존율을 기록하며 기획 의도에 부합하는 계단식 실력 분포를 나타냈다.

이는 본 연구에서 설계한 3단계 페르소나의 통제 변인이 시뮬레이션 내에서 통계적으로 유의미하게 작동하고 있음을 입증한다. 동시에, 보스 에이전트가 1.228초라는 쿨타임을 제공하고 구조적 결함이 있는 패턴(패턴 2)을 전면 배제하는 최적의 밸런스를 산출함으로써, 초보자의 전멸을 방지하고 숙련자에게도 적절한 난이도를 제공하는 통합 밸런싱 도구로서의 실무적 효용성을 완벽하게 증명한다.

2) 극단적 목표 난이도(20%, 80%) 환경에서의 행동 변화 및 물리적 상한선 분석

목표 난이도	패턴1 평균 ($Weight_1$)	패턴2 평균 ($Weight_2$)	패턴3 평균 ($Weight_3$)	패턴4 평균 ($Weight_4$)
0.2 (20%)	0.413	0.002	0.408	0.172
0.5 (50%)	0.373	0.07	0.327	0.228
0.8 (80%)	0.401	0	0.401	0.192

[표 4] 목표 난이도 설정에 따른 보스 패턴별 평균 가중치 ($Weight$) 분포

본 모델은 학습 과정에서 0.2부터 0.8 사이의 무작위 목표 난이도를 지속적으로 관측하며 정책을 최적화한 다중 목표 조건부 에이전트이다. 이러한 에이전트에게 양극단의 타겟(0.2 및 0.8)을 부여했을 때 나타나는 시스템의 거동과 환경적 제약을 분석하였다.

타겟을 20%로 설정한 결과, 에이전트는 실제 클리어율을 8.3%까지 억제하며 목표를 초과 달성하였다. 그러나 이 과정에서 패턴 엔트로피는 **1.490**으로 급감하였다. 이는 앞선 가중치 분포에서 관찰되듯 특정 패턴($Weight_2$)의 가중치를 0으로 고정하는 등 행동의 편중 현상이 발생했기 때문이며, 에이전트가 플레이어를 확실히 압도하기 위해 다채로운 조합을 포기하고 확실한 효율을 내는 패턴 위주로만 공격을 전개하는 편법을 취했음을 의미한다.

더욱 치명적인 현상은 타겟을 80%로 설정했을 때 관찰되었다. 플레이어의 높은 승률을 유도해야 함에도 불구하고, 실제 클리어율은 평균 3.4%(최댓값 27%)에 머물렀다. 이 환경에서 에이전트의 쿨타임은 간헐적으로 0.13초~0.3초 대의 극단적인 최하치로 곤두박질쳤으며, 엔트로피 역시 1.523으로 저하되는 비정상적인 거동을 보였다.

이러한 정책 붕괴 현상은 시뮬레이션에 구성된 유저풀의 제한적인 회피 능력으로는 보스의 기본 제원을 극복하고 80%의 승률을 달성하는 것이 물리적으로 불가능한 상한선이기 때문에 발생한다. 도달 불가능한 목표치로 인해 극심한 가우시안 페널티(오차율 0.765)를 지속적으로 부여받은 에이전트는, 결국 올바른 보상 그래디언트를 상실하고 파라미터가 발산하는 한계를 노출하였다. 이는 자동 밸런싱 시스템에서 AI가 유의미한 파라미터를 산출하기 위해서는, 기획자가 설정하는 타겟 수치가 해당 시뮬레이션 생태계의 물리적 한계치 내에 논리적으로 존재해야 함을 실증적으

로 시사한다.

추가로 주목할 점은, 에이전트가 비교적 안정적인 정책을 형성했던 50% 타겟 환경에서도 패턴 2(하단 공격)의 평균 사용 비중이 7%에 불과했다는 사실이다. 이는 본 시뮬레이션 환경 내에서 페르소나 에이전트의 체공(점프) 회피 능력이 보스의 하단 공격 판정 대비 과도하게 높게 설정되어, 보스가 해당 패턴을, 기대 보상이 없는 비효율적 행동으로 판단하였음을 시사한다. 결과적으로 본 연구의 밸런싱 파이프라인은 파라미터 자동 산출을 넘어, 기획자가 설계한 특정 전투 패턴의 구조적 결함이나 잉여성을 개발 초기 단계에서 데이터 기반으로 판별해 내는 자동화된 QA 도구로서의 역할도 수행할 수 있음을 입증한다.

V . 결론

본 연구는 액션 게임의 PVE 보스 전투 콘텐츠에서 기획자의 수동적이고 반복적인 밸런싱 테스트 비용을 절감하고, 목표 난이도에 수렴하는 전투 파라미터를 자동으로 산출하기 위해 경험 중심 절차적 콘텐츠 생성과 강화학습 기반의 통합 밸런싱 파이프라인을 제안하였다.

이를 위해 다중 실력 기반의 플레이어 페르소나를 모델링하여 무작위 유저 혼합 시뮬레이션 환경을 구축하였으며, 단일 에피소드 평가의 한계인 통계적 노이즈를 제어하기 위해 $N=100$ 단위의 배치 평가 시스템을 도입하였다. 특히, 밸런싱 학습의 고질적인 문제인 국소 최적해 정체 및 보상 착시 현상을 극복하기 위해 오차율에 따라 페널티가 지수적으로 감쇠하는 가우시안 보상 함수를 설계 및 적용하였다.

실험 결과, 제안하는 가우시안 보상 모델은 선형 보상 모델이 35,000 스텝 동안 발산하며 실패한 것과 대조적으로, 150,000 스텝 이내에 안정적인 뚜렷한 우상향 수렴 곡선을 그려내며 학습 성능의 우수성을 입증하였다. 또한, 타겟 난이도 50% 환경에서의 추론 테스트를 통해, 에이전트가 무작위 유저풀이 유발하는 극심한 환경적 분산 속에서도 평균 1.0초의 쿨타임을 조절하고 4가지 패턴을 고르게 섞어 쓰는 높은 엔트로피(1.719)의 최적 정책을 형성함을 확인하였다.

나아가, 분포 외(OOD) 타겟인 20% 및 80% 난이도 테스트를 통해 에이전트의 정책 붕괴 현상을 분석함으로써, 시뮬레이션 생태계에 내재된 물리적 제약을 정량적으로 규명하였다. 이 과정에서 에이전트가 효율성이 떨어지는 특정 패턴을 스스로 판별하고 배제하는 현상을 입증함으로써, 본 제안 모델이 단순한 파라미터 산출을 넘어 기획 초기 단계에서 전투 디자인의 구조적 결함과 잉여성을 검증하는 자동화된 QA 도구로 실무에 적용될 수 있는 높은 잠재력을 확인하였다. 향후 본 시스템이 다양한 게임의 복잡한 PVE 콘텐츠나 고도화된 전투 환경으로 확장 적용된다면, 효율적이고 정교한 게임 밸런싱 패러다임을 선도하는 핵심 기반 기술로 활용될 수 있을 것으로 기대된다.

참고 문헌

- [1] Yannakakis, G. N., & Togelius, J. (2011). Automated playtesting with procedural personas through MCTS with evolved heuristics. *IEEE Transactions on Games*, 3(3), 264-274.
- [2] Juliani, A., et al. (2018). Unity: A general platform for intelligent agents. *arXiv preprint arXiv:1809.02627*.
- [3] Schulman, J., et al. (2017). Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- [4] Devlin, S., & Kudenko, D. (2012). Dynamic potential-based reward shaping. *Proceedings of the 11th International Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, 765-772.
- [5] Zheng, Y., et al. (2019). Wuji: Automatic online combat game testing using deep reinforcement learning. *Proceedings of the 2019 IEEE Conference on Games (CoG)*, 1-8.
- [6] Gudmundsson, S., et al. (2018). Human-like playtesting with deep learning. *2018 IEEE Conference on Computational Intelligence and Games (CIG)*, 1-8.
- [7] Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529-533.
- [8] Bouteiller, Y., et al. (2020). Reinforcement learning with random delays. *International Conference on Learning Representations (ICLR)*.
- [9] LeCun, Y., et al. (1998). Efficient backprop. In *Neural networks: Tricks of the trade* (pp. 9-48). Springer, Berlin, Heidelberg.